# Classificação de código Fonte Utilizando Características de Textura de Code Minimaps

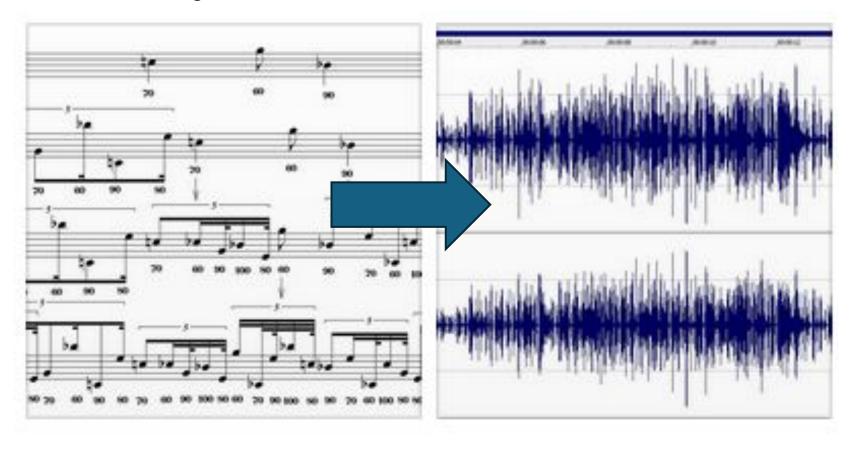
Munif Gebara Junior, (UEM)

Dr. Yandre Maldonato e Gomes da Costa (UEM)

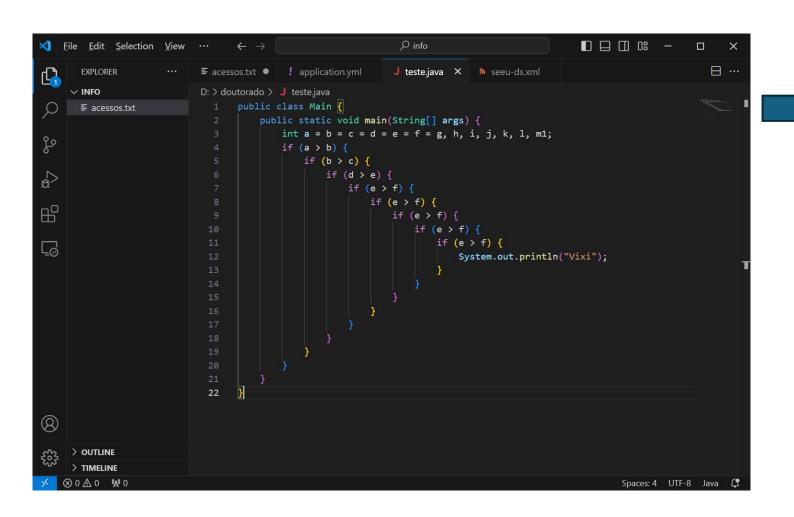
Dr. Igor Wiese, (UTFPR)

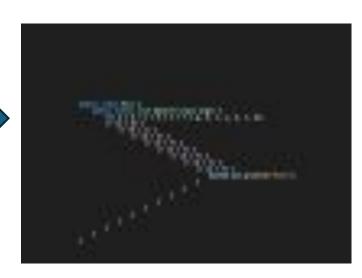
### Referencial teórico

- COSTA, Y. M. G.; Oliveira, L.S.; Koerich, A.L.; GOUYON, F.; Martins, J.G. Music
- Genre Classification Using LBP Textural Features



### MiniMap





### Criação do Dataset automátizada

```
with open(caminho_arquivo, 'r', encoding=encoding) as arquivo:
    for linha in arquivo:
        for x in range(len(linha.strip())):
            v = ord(linha[x])
            v = encrypt_chars(v)
            if v > 255:
                V = 255
            try:
                imagem.putpixel( xy: (x, y), value: (v, v, v))
            except IndexError:
                print(largura, altura, x, y, v)
        V += 1
caminho_saida_com_tipo = caminho_saida + '/' + tipo + '/'
os.makedirs(caminho_saida_com_tipo, exist_ok=True)
arquivoImagem = create_16_digit_hash(caminho_arquivo) + '.png'
imagem.save(caminho_saida_com_tipo + arquivoImagem)
```

## Criar um Dataset classificando Estereótipos

Fase Atual











brcommuniftrein amentohibernate demoentidadesa cademicoAlun...



brcommuniftrein amentohibernate demoentidadesa cademicoPesso...



brcommuniftrein amentohibernate demoentidadesa cademicoCoisa...



brcommuniftrein amentohibernate demoentidadesa cademicoCurs...



brcommuniftrein amentohibernate demoentidadesa cademicoDisci...

brcommuniftrein



brcommuniftrein amentohibernate demoentidadesa cademicoDoce...



brcommuniftrein amentohibernate demoentidadesa cademicoMatri...



brcommuniftrein amentohibernate demoentidadesa cademicoTurm...



cademicoUnid...







amentohibernate demoentidadesP

ais.java.png



### Padronizar tamanho da saída





5.png













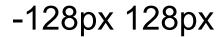


1.png









- -Bordas 8px
- -Área com dados 128px-8px-8px 112px 112px



















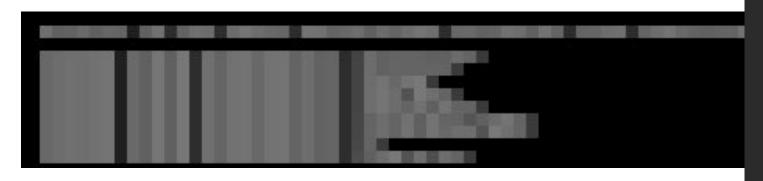


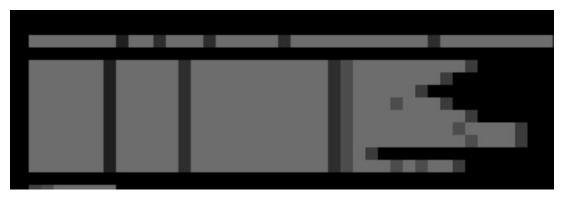


Impedir engenharia reversa do código

fonte

- -Hash do nome dos arquivos
- -Código ASCII transformado





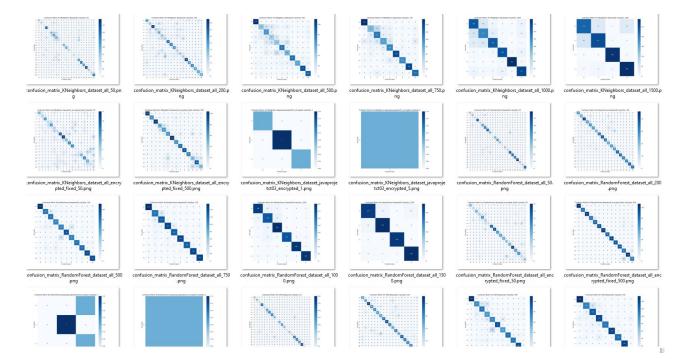
```
def encrypt_chars(asc_code): 1 usage new *
    if asc_code < 33: # não-imprimíveis</pre>
        return 32
    if asc_code < 48: # simbolos
        return asc_code
    if asc_code < 58: # números
        return 53
    if asc_code < 65: # simbolos
        return asc_code
    if asc_code < 91: # maiúsculas
        return 77
    if asc_code < 97: # simbolos
        return asc_code
    if asc_code < 123: # minúsculas
        return 109
    if asc_code < 127: # simbolos</pre>
        return asc code
    return 130
```

#### Base de Dados

14 Classes

500 amostras em cada classe]

https://github.com/munifgebara/codeminimap

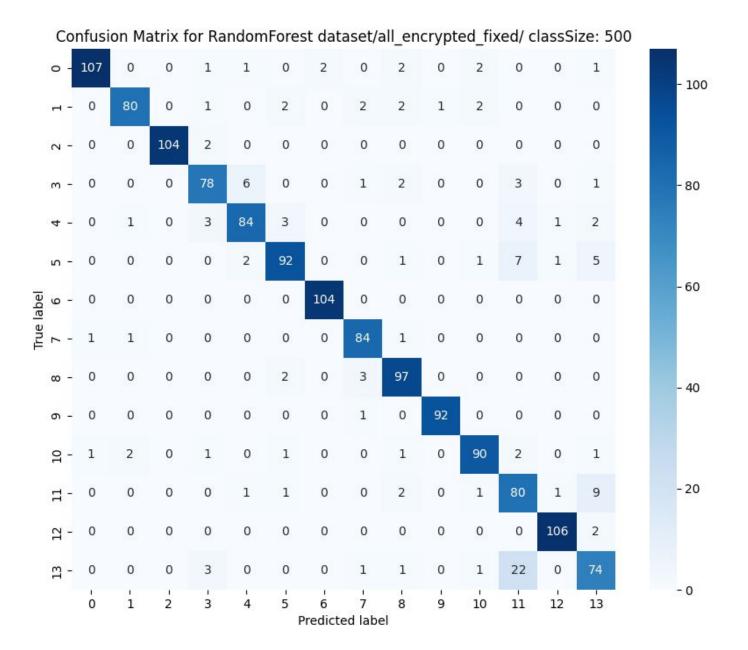


- 0 css
- 1 html
- 2 javaconverter
- 3 javadto
- 4 javaentity
- 5 javaimplementation
- 6 javajasper
- 7 javajsp
- 8 js
- 9 json
- 10 sql
- 11 javaintegrationtest
- 12 javajsf
- 13 javaunittest

### Resultados

```
0 css
1 html
2 javaconverter
3 javadto
4 javaentity
5 javaimplementation
6 javajasper
7 javajsp
8 js
9 json
10 sql
11 javaintegrationtest
12 javajsf
13 javaunittest
```

accuracy	0.91
macro avg	0.91
weighted avg	0.91



### Próximos passos

- Criar outros datasets:
  - Repositórios open source e privados
  - Outras linguagens
  - Outras classificações
  - Outros tipos de textos
- Comparar com outros métodos
- Responder: "Tais métodos são promissores para análise de código fonte?
- Tenar deep learning
  - Publicar dataset e artigo

## Feature Detection in Software: A Source Code Mini-Map Approach

Decoding Software using Sourcecode mini-maps to identify programming Languages and stereotypes

1st Munif Gebara Junior DIN

2<sup>nd</sup> Yandre Costa DIN

3<sup>rd</sup> Igor Wiese 222222

UEM - State University of Maringá UEM - State University of Maringá UTFPR - Federal University of Technology (Brazil) Maringá, Brazil pg55752@uem.br

Maringá, Brazil ymgcosta@uem.br

Paraná, Braszil igor.wiese@gmail.com

Abstract—This document is a model and instructions for LATEX. This and the IEEEtran.cls file define the components of your paper [title, text, heads, etc.]. \*CRITICAL: Do Not Use Symbols, Special Characters, Footnotes, or Math in Paper Title or Abstract.

*Index Terms*—component, formatting, style, styling, insert

#### INTRODUCTION

#### B. Units

- Use either SI (MKS) or CGS as primary units. (SI units are encouraged.) English units may be used as secondary units (in parentheses). An exception would be the use of English units as identifiers in trade, such as "3.5-inch disk drive".
- Avoid combining SI and CGS units, such as current