

Dados, Questões de pesquisa e Resoluções

Progresso de desenvolvimento

import pandas as pd

Biblioteca fundamental para análise de dados em Python. Ela fornece estruturas de dados eficientes, como DataFrame e Series, que facilitam a manipulação e a análise de dados tabulares.

Progresso de desenvolvimento

```
from sklearn.model_selection import train_test_split
```

Esta função divide um conjunto de dados em conjuntos de treinamento e teste. Isso é essencial para avaliar o desempenho de modelos de aprendizado de máquina.

Progresso de desenvolvimento

from sklearn.ensemble import RandomForestClassifier

RandomForestClassifier é um modelo de aprendizado de máquina que utiliza uma combinação de várias árvores de decisão (floresta aleatória) para classificar dados. Ele é robusto e pode lidar com dados de alta dimensão e interações não lineares.

Progresso de desenvolvimento

from sklearn.metrics import accuracy_score

Esta função calcula a acurácia de um modelo, que é a proporção de previsões corretas em relação ao total de previsões feitas.

- Fórmula: $\text{Acurácia} = \frac{\text{Número de Previsões corretas}}{\text{Total de Previsões}}$

Progresso de desenvolvimento

from sklearn.preprocessing import LabelEncoder

LabelEncoder é uma classe que converte rótulos categóricos em números inteiros. Isso é útil para preparar dados antes de treinar modelos, já que muitos algoritmos de aprendizado de máquina não podem trabalhar diretamente com dados categóricos.

Progresso de desenvolvimento

```
from sklearn.feature_extraction.text import TfidfVectorizer
```

TfidfVectorizer é uma ferramenta para converter um conjunto de documentos de texto em uma matriz de características utilizando a técnica TF-IDF (Term Frequency-Inverse Document Frequency).

Progresso de desenvolvimento

```
from sklearn.feature_extraction.text import TfidfVectorizer
```

TfidfVectorizer é uma ferramenta para converter um conjunto de documentos de texto em uma matriz de características utilizando a técnica TF-IDF (Term Frequency-Inverse Document Frequency).



Common Weakness Enumeration

A community-developed list of SW & HW weaknesses that can become vulnerabilities

1425 - Weaknesses in the 2023 CWE Top 25 Most Dangerous Software Weaknesses

- **B** Out-of-bounds Write - (787)
- **B** Improper Neutralization of Input During Web Page Generation ('Cross-site Scripting') - (79)
- **B** Improper Neutralization of Special Elements used in an SQL Command ('SQL Injection') - (89)
- **V** Use After Free - (416)
- **B** Improper Neutralization of Special Elements used in an OS Command ('OS Command Injection') - (78)
- **C** Improper Input Validation - (20)
- **B** Out-of-bounds Read - (125)
- **B** Improper Limitation of a Pathname to a Restricted Directory ('Path Traversal') - (22)
- **C** Cross-Site Request Forgery (CSRF) - (352)
- **B** Unrestricted Upload of File with Dangerous Type - (434)
- **C** Missing Authorization - (862)
- **B** NULL Pointer Dereference - (476)
- **C** Improper Authentication - (287)
- **B** Integer Overflow or Wraparound - (190)
- **B** Deserialization of Untrusted Data - (502)
- **C** Improper Neutralization of Special Elements used in a Command ('Command Injection') - (77)
- **C** Improper Restriction of Operations within the Bounds of a Memory Buffer - (119)
- **B** Use of Hard-coded Credentials - (798)
- **B** Server-Side Request Forgery (SSRF) - (918)
- **B** Missing Authentication for Critical Function - (306)
- **C** Concurrent Execution using Shared Resource with Improper Synchronization ('Race Condition') - (362)
- **C** Improper Privilege Management - (269)
- **B** Improper Control of Generation of Code ('Code Injection') - (94)
- **C** Incorrect Authorization - (863)
- **B** Incorrect Default Permissions - (276)

Após classificar todas as 25 vulnerabilidades com o Dataset e aplicar as bibliotecas e ferramentas, o próximo passo está sendo calibrar os resultados variados devido a variabilidade de diversos códigos de linguagens diferentes contidas entre as vulnerabilidades.

Questões de Pesquisa e Resoluções

- Existe uma ou mais vulnerabilidades com 100% de eficácia de detecção pelo software? A que se deve esse fator?
- Existe uma ou mais vulnerabilidades com 0% de eficácia de detecção pelo software? A que se deve esse fator?
- Quantos caracteres ou linhas de código podem ser modificadas em código anteriormente analisado e detectado para que o software seja incapaz de reconhecer a vulnerabilidade?